

# Previsão de Valores de Aluguéis de Imóveis na Cidade de Bambuí - MG

1° Jean Lúcio Campos  
Instituto Federal de Minas Gerais (IFMG)  
camposjl2020@gmail.com

2° Patrícia Crescêncio Martins  
Instituto Federal de Minas Gerais (IFMG)  
pcrescenciomartins@gmail.com

**Abstract**—A compreensão das tomadas de decisões fundamentadas é de suma importância para proprietários, investidores e profissionais do mercado imobiliário, dada a relevância das dinâmicas envolvidas. A previsão de preços de aluguéis fornece *insights* para estratégias de precificação, estimativas de receita futura e viabilidade de projetos imobiliários, assim como também auxilia no planejamento financeiro e negociações contratuais justas. Este trabalho visa compreender as tendências e padrões do mercado imobiliário na cidade de Bambuí, Minas Gerais (MG), prevendo os preços de aluguéis com base em um conjunto de dados que abrange o período de 2020 a 2023 e utilizando uma *Deep Neural Network* (DNN). Foram analisadas 50 amostras de dados, tratando as entradas e saídas para treinar o tipo de rede neural artificial selecionado. Após a rede ser treinada e testada no conjunto, os resultados obtidos foram satisfatórios com 11,74% de erro, o que representa uma variação média de R\$287,75. Com estes resultados foi possível verificar a eficiência da rede para o tipo de problema em questão e assim, abre espaço para trabalhos futuros em que o treinamento e teste da DNN podem ser feitos seguindo o modelo inicial aqui proposto, aplicando-o em bases de dados maiores, para previsões de preços de aluguéis futuros.

**Index Terms**—Mercado Imobiliário, Preços de Aluguéis, *Deep Neural Network*

## I. INTRODUÇÃO

O mercado imobiliário é alvo de muitas pesquisas, principalmente quando falamos de precificação, isso ocorre, pois investidores e proprietários de imóveis, por exemplo, se interessam em saber as tendências do mercado e suas variações, já que estas irão influenciar nas “decisões das pessoas sobre investimentos imobiliários e cidades para trabalhar e residir, bem como a análise e desenvolvimento de políticas das agências reguladoras” [1].

Ainda segundo [1], muitos estudos tem sido empregados com o objetivo de realizar previsões quanto ao mercado imobiliário, inclusive quanto aos aluguéis dos imóveis. Isso pode ser feito por meio de diversas técnicas presentes na área de Economia como o estudo de séries temporais e na área da Ciência da Computação, em que se destaca a grande quantidade de pesquisadores que utilizam inúmeras técnicas de Inteligência Artificial (IA) com este objetivo.

Tomando como referência o trabalho [1], é apresentado que o uso de redes neurais para previsão em mercados imobiliários tem se mostrado eficiente, ainda mais quando consideramos séries temporais.

A previsão de preços de aluguéis é uma tarefa em que se deve tomar os devidos cuidados, visto a complexidade e a influência de diversos fatores envolvidos. A determinação do preço de um aluguel pode depender de aspectos como a localização do imóvel, infraestrutura disponível na região, demanda por aluguéis, entre outros. Portanto, é necessário analisar um conjunto de características relevantes e identificar padrões que relacionem essas características com os preços observados.

Sendo assim, o presente trabalho, apesar de almejar realizar a previsão de aluguéis de imóveis não terá como variável o tempo, ou seja, as datas de aluguéis dos imóveis, isso, pois, no *dataset* utilizado, não houve uma variação considerável no valor dos imóveis com o passar do tempo. Além disso, a base de dados é composta por apenas 50 amostras e estes imóveis, estão compreendidos apenas no período de 2020 ao início de 2023. Foi observado assim que essa variável não possui grande influência para o conjunto em estudo.

Dessa maneira, este artigo apresenta o desenvolvimento do Trabalho Final da disciplina de Tópicos Especiais em Engenharia de Computação do 1º semestre letivo do ano de 2023. O objetivo foi implementar uma *Deep Neural Network* capaz de realizar a previsão dos valores cobrados em aluguéis de imóveis na cidade de Bambuí - MG, em que se situa o *campus* do IFMG em que os autores estudam.

Percebe-se que a previsão de preços de aluguéis é uma ferramenta útil para proprietários e inquilinos na negociação de contratos justos, bem como para investidores imobiliários que desejam calcular retornos sobre o investimento e tomar decisões informadas sobre a compra ou venda de propriedades.

## II. CARACTERIZAÇÃO DO PROBLEMA

O presente trabalho visou realizar a previsão dos aluguéis de imóveis por meio de um *dataset* obtido pelos próprios autores, através da solicitação dos dados à duas imobiliárias da cidade em questão, sendo elas Imobiliária Nunes e Bolsa Corretora de Imóveis, considerando os preços observados no período de 2020 a 2023. Além disso, foram inseridos no *dataset* alguns imóveis de familiares e amigos dos autores. Assim, no total foram obtidas 50 amostras de imóveis.

O *dataset* apresenta como entradas as categorizações quanto ao bairro da cidade em que o imóvel se localiza, número

de banheiros, número de quartos ou repartições (em caso de imóveis comerciais), número correspondente a quantidade de carros que a garagem disponível no imóvel suporta e por fim o tipo no imóvel, podendo ser uma casa, apartamento ou com objetivo comercial.

Os bairros são um total de 13, para os dados coletados, estes foram definidos conforme as informações disponibilizadas pelas empresas imobiliárias e também pelos proprietários dos imóveis, além de ser comparado com o mapa da cidade disponível no *site* [2] da prefeitura municipal, que considera, por exemplo, o bairro Candola e Sion como únicos. Os bairros foram enumerados de 0 a 12 conforme descrição a seguir:

- N. Senhora de Fátima: 0
- Centro: 1
- Nações: 2
- Candola/Sion: 3
- Açudes: 4
- Nova Rodoviária: 5
- Cerrado: 6
- Jardim America: 7
- São Conrado: 8
- Gabiroba: 9
- Rola Moça: 10
- Nª Senhora das Graças: 11
- Sagrado Coração de Jesus: 12

Quanto ao tipo do imóvel, a numeração foi da seguinte forma, de 0 a 2:

- Comercial: 0
- Casa: 1
- Apartamento: 2

Assim sendo, foi desenvolvida uma DNN para previsão dos valores de aluguéis de imóveis a partir do *dataset* obtido. Além disso, a linguagem utilizada para a implementação da rede foi *Python*, por ser uma linguagem que fornece muitas bibliotecas úteis para a análise e treinamento dos dados.

### III. OBJETIVO

O objetivo deste trabalho consiste em desenvolver um modelo de previsão de preços de aluguéis mensais de imóveis na cidade de Bambuí, interior de Minas Gerais. Por meio da análise de um conjunto de dados contendo informações sobre algumas características dos imóveis e os preços de aluguéis correspondentes. O modelo foi treinado utilizando uma abordagem de aprendizado de máquina, mais especificamente, uma *Deep Neural Network*.

Ao obter o modelo, torna-se possível estimar os preços de aluguéis de imóveis na cidade em questão com base nas características dos imóveis, como número de quartos, capacidade das garagens, localização, entre outros, já apresentados anteriormente. Isso proporciona *insights* para proprietários, inquilinos e investidores, permitindo tomar decisões mais assertivas no mercado imobiliário.

Além disso, o trabalho busca contribuir para a compreensão do mercado imobiliário em Bambuí, auxiliando no planejamento financeiro e negociações contratuais, contribuindo assim para o mercado imobiliário nessa região específica. A falta

de estudos similares na cidade torna essa pesquisa relevante para preencher essa lacuna de conhecimento e proporcionar informações para diversos interessados no setor imobiliário local.

### IV. TRABALHOS RELACIONADOS

Observamos que na cidade de Bambuí não foram encontrados estudos visando realizar previsões de aluguéis de imóveis, no entanto, a seguir, apresentamos alguns exemplos de pesquisas semelhantes em outras regiões.

Como exemplo, temos o trabalho [3], em que os autores utilizaram uma *Multilayer Perceptron* (MLP) para prever os preços de imóveis em condomínios em Cingapura, assim como também utilizaram outro modelo chamado ARIMA, para fins de comparação. Foi destacado que a MLP proporcionou resultados melhores. Como se tratava da previsão especificamente em condomínios, os autores consideraram características como produto interno bruto (PIB), população, índice de preços de revenda, variação do índice de preços de revenda, número de condomínios disponíveis e índice de preços de condomínios, dentre outros.

Por sua vez, o trabalho [4] apresenta um modelo de previsão de aluguéis na cidade de Chengdu, na China. Como dados de entrada foram escolhidos a área habitacional, orientação, modo de cobrança do aluguel, transporte, estrutura, etc. Fazendo uma análise dos dados foi identificado que os residentes na cidade têm uma demanda maior por aluguéis em conjunto e apartamentos com áreas menores. As previsões foram realizadas pelos algoritmos *RandomForestRegressor*, *XGBoost* e *LightGBM*, e a melhor precisão de previsão foi entregue pelo modelo *XGBoost* através do ajuste de parâmetros.

Esses dois são apenas alguns exemplos de trabalhos que abordaram a previsão de preços de imóveis usando técnicas de aprendizado de máquina. Como observado anteriormente, não foram encontrados estudos específicos que se dedicaram à previsão de preços de aluguéis de imóveis na cidade de Bambuí, Minas Gerais. Portanto, este trabalho objetiva preencher essa lacuna e contribuir com conhecimentos específicos sobre o mercado imobiliário nessa região.

### V. FUNDAMENTAÇÃO TEÓRICA

Até o momento, diversos trabalhos têm se dedicado à previsão de preços de aluguéis de imóveis em diferentes regiões e contextos. Alguns desses trabalhos utilizaram abordagens de aprendizado de máquina para desenvolver modelos de previsão.

#### A. Inteligência Artificial

Inteligência Artificial é um campo da Ciência da Computação que se concentra no desenvolvimento de sistemas e algoritmos capazes de realizar tarefas que exigem habilidades humanas, como raciocínio, aprendizado, resolução de problemas e percepção. A IA envolve a construção de agentes inteligentes que podem perceber o ambiente, tomar decisões e interagir com ele de forma autônoma.

A definição abrangente de IA pode ser atribuída a John McCarthy, um dos pioneiros da IA, que a descreveu como "a ciência e engenharia de fazer máquinas inteligentes" [5]. Essa definição destaca o objetivo de criar sistemas que possam exibir comportamento inteligente semelhante ao humano.

Existem várias abordagens na IA, incluindo a lógica simbólica, a aprendizagem de máquina e as redes neurais artificiais que são o foco desse trabalho. Essas abordagens visam modelar o raciocínio humano e desenvolver algoritmos que possam aprender a partir de dados e melhorar seu desempenho ao longo do tempo.

### B. Aprendizado de Máquina

O aprendizado de máquina também conhecido como *machine learning* (ML) é um campo da IA cujo objetivo é desenvolver ferramentas computacionais que possam tomar decisões com base em experiências passadas sem intervenção humana. Essas experiências são geradas pela entrada de dados como hipóteses, regras e padrões. A partir desses conjuntos de dados de entrada, os algoritmos de computador são treinados para derivar funções ou possibilidades que podem resolver problemas. Por serem algoritmos eficientes e eficazes, há muito espaço para melhorias em suas aplicações [6].

### C. Deep Neural Network

Uma *Deep Neural Network* (DNN) refere-se a uma arquitetura específica de rede neural artificial composta por múltiplas camadas ocultas. Essas camadas ocultas permitem que a rede neural aprenda características complexas e abstratas dos dados de entrada, o que a torna capaz de realizar tarefas de aprendizado profundo, como classificação, reconhecimento de padrões, processamento de linguagem natural e visão computacional.

As DNN podem ser utilizadas para os fins mencionados devido à sua capacidade de aprender automaticamente os melhores modelos para os dados. O algoritmo Adam (*Adaptive Moment Estimation*) é um otimizador popularmente utilizado no treinamento de redes neurais e outros algoritmos de aprendizado de máquina. Ele foi proposto por Diederik P. Kingma e Jimmy Lei Ba em 2015 [7].

O algoritmo Adam tem sido amplamente utilizado no treinamento de redes neurais profundas. Ele oferece vantagens significativas, como adaptação da taxa de aprendizado para cada parâmetro individualmente, ajustando-a com base nas estimativas do primeiro e segundo momento dos gradientes. Isso ajuda a otimizar o processo de treinamento, permitindo que as DNN sejam ajustadas de forma mais eficiente aos dados disponíveis.

O algoritmo Adam é valorizado por sua eficiência e eficácia no treinamento de DNN. A combinação do momento e do método de adaptação da taxa de aprendizado permite que ele se adapte dinamicamente às características dos dados e às variações dos gradientes. Isso ajuda a evitar o problema de taxas de aprendizado fixas inadequadas, melhorando o desempenho do treinamento e a convergência das DNN.

Apesar de suas vantagens, o algoritmo Adam também tem algumas limitações e variantes. Por exemplo, pode ter dificuldade em lidar com tarefas que requerem ajustes finos devido à alta taxa de aprendizado inicial. Existem também variantes do algoritmo, como o Adamax e o Nadam, que foram propostas para melhorar ainda mais o desempenho e a estabilidade em diferentes cenários de treinamento.

### D. Deep Learning

Segundo [8], o *deep learning*, ou aprendizado profundo, permite que modelos computacionais compostos por várias camadas de processamento aprendam representações de dados com vários níveis de abstração. Esses métodos melhoraram drasticamente o estado da arte em reconhecimento de fala, reconhecimento visual de objetos, detecção de objetos e muitos outros domínios, como descoberta de medicamentos e genômica.

Sendo assim, [8] reforça que o aprendizado profundo descobre estruturas complexas em grandes conjuntos de dados usando o algoritmo de retropropagação (*backward*) para indicar como uma máquina deve alterar seus parâmetros internos usados para calcular a representação em cada camada a partir da representação na camada anterior. As redes convolucionais profundas trouxeram avanços no processamento de imagens, vídeo, fala e áudio, enquanto as redes recorrentes beneficiaram os dados sequenciais, como texto e fala.

Logo, essa forma de aprendizado trata-se do processo de treinar uma rede neural profunda, como uma DNN *Deep Neural Network*, em grandes volumes de dados para aprender e melhorar sua capacidade de realizar tarefas específicas.

O aprendizado ocorre através da alimentação de exemplos rotulados (dados de treinamento) à rede neural, permitindo que ela ajuste seus pesos e parâmetros internos de acordo com a informação contida nesses dados. Com o tempo, a DNN se torna capaz de generalizar o aprendizado para novos dados não vistos anteriormente (dados de teste) e realizar previsões ou inferências com base nesses dados.

### E. Diferenças entre DNN e MLP

Uma *Deep Neural Network* e uma *Multi-Layer Perceptron* são termos frequentemente usados de forma intercambiável, mas existem algumas diferenças sutis e que, na prática, provocam resultados diversos.

Em termos gerais, uma MLP é uma arquitetura específica de rede neural artificial que consiste em várias camadas ocultas de neurônios, além de uma camada de entrada e uma camada de saída. Cada neurônio em uma camada oculta está conectado a todos os neurônios da camada anterior e da camada seguinte, formando uma rede completamente conectada. A MLP é um exemplo de uma rede neural *feedforward*, onde as informações fluem apenas em uma direção, da entrada para a saída.

Por outro lado, o termo *Deep Neural Network* é mais abrangente e refere-se a qualquer rede neural artificial que tenha múltiplas camadas ocultas, independentemente da arquitetura específica. Portanto, uma MLP também pode ser considerada uma DNN se tiver múltiplas camadas ocultas.

No entanto, o termo *Deep Neural Network* também é frequentemente usado para se referir a arquiteturas de redes neurais mais complexas e profundas, como redes neurais convolucionais (CNN) e redes neurais recorrentes (RNN), que têm sido usadas com sucesso em tarefas como visão computacional, processamento de linguagem natural e sequência de dados.

[9] afirma que as DNN estendem as redes neurais tradicionais para ter camadas profundas com alta dimensão de parâmetros e os modelos DNN evoluíram para ter diferentes estruturas para diferentes aplicações, incluindo as MLP, as CNN e ainda redes de crenças profundas (DBN) usadas na classificação e reconhecimento de imagens e autoencoders profundos usados em imagens.

Em resumo, uma MLP é um tipo específico de DNN que segue uma estrutura de camadas ocultas completamente conectadas, no caso deste trabalho, por utilizar o algoritmo Adam, ele se torna uma DNN que é um termo mais amplo e que abrange qualquer rede neural artificial com múltiplas camadas ocultas.

## VI. METODOLOGIA

A presente seção apresenta como foi o desenvolvimento da rede neural artificial selecionada.

### A. Análise dos dados

A primeira etapa a ser seguida para o desenvolvimento do modelo é realizar a análise dos dados, como segue.

A Figura 1 apresenta a distribuição dos valores dos imóveis presentes no *dataset* e organizados pela frequência com que eles ocorrem, assim havendo imóveis de 350 a 2800 reais, o que representa uma variação total de R\$2450.

Além disso, pode-se observar através da sumarização estatística que a média dos valores pagos nos alugueis desses imóveis é em torno de R\$1040 e o desvio padrão é de R\$424,93, como mostra a Figura 2.

A Figura 3 apresenta, por sua vez, a ocorrência dos imóveis de acordo com o bairro, seguindo a numeração apresentada na Introdução. Por meio da Figura 3 já podemos observar um problema do *dataset* para o treinamento da rede, que é o fato de haver alguns bairros que apresentam apenas um imóvel. Isso pode fazer com que a DNN tenha dificuldade em identificar padrões para os valores de alugueis dos imóveis nessas regiões.

Como apresentado anteriormente, os demais dados de entrada são quantidade de banheiros, quartos/repartições comerciais, capacidade da garagem e tipo, essas entradas e a quantidade de imóveis correspondentes são apresentadas na Figura 4 e 5.

### B. Tratamento dos dados

Os dados de entrada se tratam de variáveis do tipo categóricas, ou seja, cada dado das variáveis de entrada indicam que a amostra em questão pertence a um determinado grupo, de modo que as possibilidades são limitadas e não contínuas.

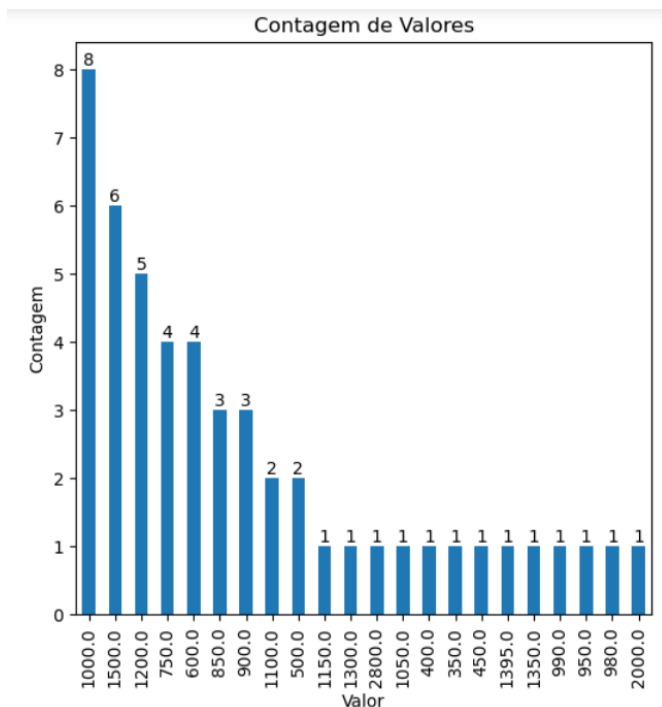


Fig. 1. Frequência de valor dos imóveis.

Coluna	Máximo	Mínimo	Média	Mediana	Desvio Padrão
Valor	2800	350	1040.3	1000	424.93

Fig. 2. Sumarização estatística.




Fig. 3. Frequência dos imóveis por bairro.

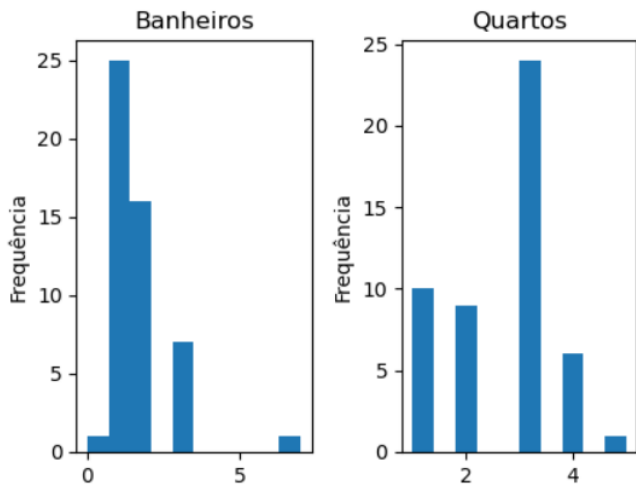


Fig. 4. Frequência dos imóveis por números de banheiros e quartos.

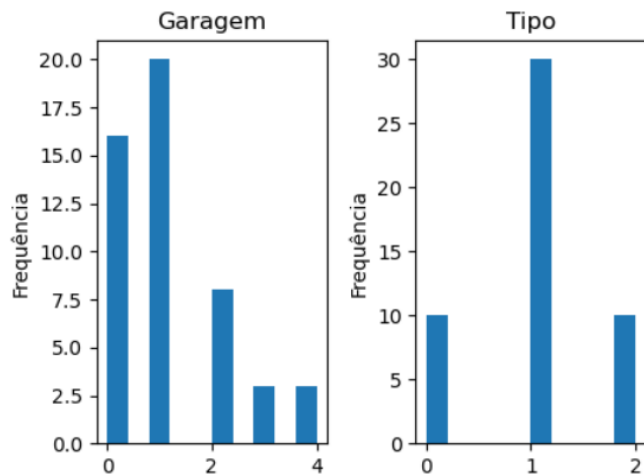


Fig. 5. Frequência dos imóveis por capacidade da garagem e tipo.

Já no caso da variável de saída, que é o valor pago pelo aluguel mensal do imóvel, temos uma variável contínua, medida em reais. Sendo assim, os seus dados foram ajustados para uma escala de 0 a 1, por meio de um escalonamento, o que faz com que os dados fiquem mais padronizados para o posterior treinamento da rede. O resultado obtido após esse tratamento é apresentado na Figura 6 que pode ser, inclusive, comparada com a Figura 1.

No caso do bairro, por exemplo, que varia de 0 a 12, um imóvel se localizar no bairro 0 ou no bairro 3 não faz com que um seja melhor que o outro, por isso colocar em uma escala crescente, de 0 a 1, não seria o mais adequado. Dessa maneira essas entradas foram tratadas e representadas por meio de uma função chamada *OneHotEncoder* de uma biblioteca do Python, a *scikit-learn*.

A função *OneHotEncoder* faz a representação dos valores utilizando apenas 0 e 1. Um exemplo simples para o *dataset* utilizado é quanto à variável tipo, que pode ser 0, 1 ou 2, ao utilizar a função esses valores serão convertidos para 100, 010




Fig. 6. Valores de saída após escalonamento

e 001 respectivamente.

Dessa maneira, após tratar o *dataset* original, que inicialmente possuía 5 colunas de dados de entrada, obteve-se 31 colunas para prever a única saída que representa o valor do aluguel do imóvel na última coluna.

### C. Configuração do modelo de previsão

O modelo de rede neural escolhida para desenvolvimento deste trabalho foi o de DNN por meio do algoritmo Adam.

Como apresentado anteriormente, após o tratamento dos dados, obteve-se 31 entradas para os neurônios. Quanto ao número de camadas de neurônios, como se trata de uma base de dados com apenas 50 amostras, o uso de menos camadas proporcionou melhores resultados, sendo configurada com apenas 2: a primeira ficou com 16 neurônios e a segunda com 8 e já se liga com a camada de saída, como mostra a Figura 7.




Fig. 7. Esquema do modelo desenvolvido

A função de ativação escolhida foi a tangente hiperbólica, que se trata de uma função que mapeia valores na faixa de -1 a 1. No caso do presente trabalho, são mapeados valores na faixa de 0 a 1, no entanto, ainda assim essa função se mostrou mais eficiente nos testes do que outras, como a sigmoid. A Figura 8 apresenta a curva da tangente hiperbólica, retirada de [10] e a Figura 9 apresenta a curva da sigmoid que varia de 0 a 1, conforme apresentado em [11].




Fig. 8. Curva da função tangente hiperbólica




Fig. 9. Curva da função sigmoid

Para o total de 50 amostras, foram separadas 40 para a fase de treinamento e validação e as 10 restantes ficaram para teste. A taxa de aprendizagem que resultou em um melhor resultado após os testes foi de 0.000009999 e com 1000 épocas. A medida para análise do erro utilizada foi o erro quadrático médio.

A Figura 10 apresenta a curva do convergência do erro durante as épocas, apesar de o formato da curva indicar que a taxa de aprendizagem está alta, ao diminuir seu valor os resultados foram menos satisfatórios.

Para cada execução, como os dados para treino são selecionados e embaralhados podem haver resultados um pouco diferentes, porém aqui registramos alguns resultados relativamente satisfatórios considerando o pequeno tamanho do *dataset* utilizado.




Fig. 10. Curva de convergência do erro

## VII. RESULTADOS

O erro médio, medido em reais, foi de R\$287,75, o que percentualmente representa 11,74%. Sendo assim um resultado satisfatório dado o tamanho da amostra obtida.

A Figura 11 apresenta um histograma em que são apresentadas as saídas esperadas e as saídas estimadas pelo modelo de DNN desenvolvido, para as 10 amostras do conjunto de teste. Em azul mais claro estão as saídas esperadas e em azul mais escuro as saídas estimadas.

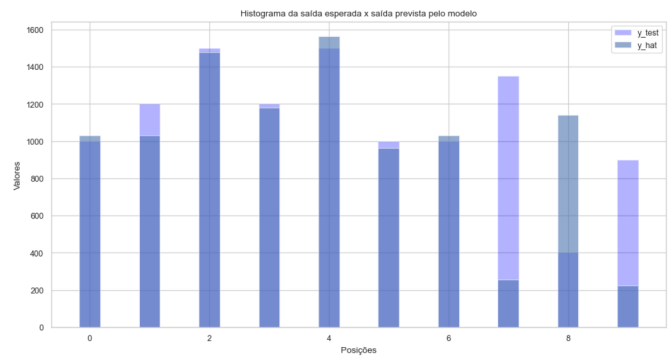


Fig. 11. Comparação das saídas esperadas com as estimadas

Analisando o histograma concluímos que realmente as saídas estimadas se aproximaram das reais, especialmente nos sete primeiros índices apresentados. Apenas os três últimos apresentaram uma diferença maior. No índice 7 a diferença foi de R\$1094,43, no índice 8 foi de R\$739,59 e no índice 9 foi de R\$ 676,03.

## VIII. CONCLUSÃO

Com o desenvolvimento do presente trabalho foi possível compreender melhor o funcionamento de uma rede neural profunda, como realizar seu treinamento e testes, buscando alcançar melhores resultados por meio da configuração da rede, incluindo suas camadas de neurônios e taxa de aprendizado.

Ainda foi possível perceber a verdadeira eficiência do uso dos algoritmos aqui utilizados para previsão de aluguéis de

imóveis, como já foi comprovado pelas referências bibliográficas.

Como sugestões de melhorias, pode-se buscar treinar a rede e ajustá-la para uma base de dados maior, isso poderá permitir um melhor treinamento da rede e logo, previsões mais precisas. Também sugere-se realizar uma diferenciação entre imóveis de corretoras imobiliárias e pessoais, pois foi possível perceber durante a coleta dos dados que os imóveis em corretoras apresentam valores mais elevados.

#### REFERENCES

- [1] X. Xu and Y. Zhang, "Rent index forecasting through neural networks," *Journal of Economic Studies*, vol. 49, no. 8, pp. 1321–1339, 2022.
- [2] Expand, "Prefeitura demarca bairros de Bambuí / Prefeitura Municipal de Bambuí."
- [3] W. T. Lim, L. Wang, Y. Wang, and Q. Chang, "Housing price prediction using neural networks," in *2016 12th International conference on natural computation, fuzzy systems and knowledge discovery (ICNC-FSKD)*, pp. 518–522, IEEE, 2016.
- [4] Y. Ming, J. Zhang, J. Qi, T. Liao, M. Wang, and L. Zhang, "Prediction and analysis of chengdu housing rent based on xgboost algorithm," in *Proceedings of the 3rd International Conference on Big Data Technologies*, pp. 1–5, 2020.
- [5] "Basic Questions."
- [6] K. Faceli, A. C. Lorena, J. Gama, and A. C. P. d. L. F. d. Carvalho, *Inteligência artificial: uma abordagem de aprendizado de máquina*. LTC, 2011.
- [7] B. A. D. P. RAIMUNDO, "Redes neurais: Estruturas de um mundo moderno,"
- [8] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [9] J. Gu, M. Zhu, Z. Zhou, F. Zhang, Z. Lin, Q. Zhang, and M. Breternitz, "Implementation and evaluation of deep neural networks (dnn) on mainstream heterogeneous systems," in *Proceedings of 5th Asia-Pacific Workshop on Systems*, pp. 1–7, 2014.
- [10] M. A. Sartin and A. C. R. da Silva, "Aproximação da função tangente hiperbólica em hardware," in *Proceedings of International Conference on Engineering and Computer Education*, vol. 8, pp. 361–365, 2013.
- [11] "Função sigmoide," May 2021. Page Version ID: 61241436.